


AI 결과를 검증 가능한 인계로

AI 에이전트의 결과를 사람과 다음 에이전트가 근거와 함께
이어받도록, 검증 가능한 인계 도구를 설계하고 구현합니다.

AI 제안 · 근거 확인 · 검토 · 수용을 연결하는 하네스



개념도 · AI 초안의 각 내용이 결정적 검사와 검토를 거쳐, 상태와 함께 인계 파일에 남는다
Work Handoff · AI Evidence Review · 에이전트 작업 조율 스킬은 런타임으로 연결되지 않은 독립 구현

이진웅 | 3년차 AI 엔지니어

LangGraph·vLLM·FastAPI 기반 온프레미스 RAG 솔루션 설계·구축

이번 포트폴리오: AI 에이전트 결과를 근거·검토 상태와 함께 인계하는 도구

이 포트폴리오의 세 사례

사례	형태	장	저장소
01 Work Handoff 대표	로컬 웹 서비스 · 인용 검사와 검증 가능한 Markdown 인계	04-05 · 07-09	github.com/dtype2100/work-handoff
02 AI Evidence Review	Python CLI · 주장 · 체크 · 판정 분리	06	github.com/dtype2100/ai-evidence-review
03 에이전트 작업 조율 스킴	직접 설계·제작한 SKILL.md · 작성 · 리뷰 · 수용 게이트	10	github.com/dtype2100/orca-orchestrate-engineering

결론만 넘겨받으면 근거를 다시 확인하기 어렵다

AI 결론만 전달되면 검토자와 다음 담당자는 원문 · 실행 증거 · 판정 상태를 다시 확인하기 어렵습니다.

① 작업 인계 요약 → Work Handoff

세션 A · 화 “Migration finished on Tuesday ...”

세션 B · 수 “Migration still running as of Wednesday ...”

합성 예시 기록 발췌 · examples/conflict

빠진 것 두 기록의 상태가 서로 어긋난다는 점, 각 문장이 어느 원문에서 왔는지

후속 판단 위험 요약이 한쪽만 옮기면 “완료”로 넘어가 다음 담당자가 확인되지 않은 상태 위에서 작업

② AI 코드 리뷰 결론 → AI Evidence Review

AI 리뷰 결론 한 문단

원인 추정

“테스트로 확인했다”는 말

수정 · 병합 권고


구조 도식 · 특정 문장을 옮긴 것이 아님

빠진 것 어떤 테스트를 어떻게 실행했는지, 그 결과가 주장을 입증하는지 누가 판단했는지

후속 판단 위험 실행했다는 말만 믿고 원인 추정을 사실로 삼아 수정 · 병합을 결정

Work Handoff: 초안 경로는 둘, 인용 검사와 검토는 같다

— 파일 · 원본 기록 [] 앱 밖 · 검사 전까지 미실행 □ 로컬 검사 · 검토 (브라우저 안)



같은 원칙의 독립 구현

AI Evidence Review 별도 Python CLI · 코드 리뷰 주장과 고정 테스트 결과를 나눠 기록 (06)
에이전트 작업 조율 스킬 직접 설계·제작한 SKILL.md, Work Handoff 제작에 쓴 작업 운영 방식 (10) · 둘 다 이 흐름과 런타임으로 연결되지 않음

기억 공유는 파일로: 남긴 파일을 다음 작업에서 다시 열 수 있다

사람

파일을 저장소에
두거나 파일 위치를
다음 작업 지시에 적음

남긴다

규칙 · 계약 .md

AGENTS.md
docs/run-
contract.md

역할 · 소유 경로 · 검사 · 수용
기준을 적은 파일

결정 위키 .md

llm-wiki/wiki/
index.md

결정마다 출처 라벨

사용자 결정 저장소 확인

관찰 미결

인계 파일 .md

work-handoff.md

항목별 원문 인용 · 검토 상태 ·
다음 조치

다시 열 수 있음

다음
에이전트

다음 작업 지시에서 인계
파일을 다시 열도록
지정할 수 있음

한계

자동 동기화 없음

앱에 저장하지 않음

실제 사용 · 효과는 관찰하지 않음

AI Evidence Review: 주장 · 체크 · 판정을 파일로 분리

명령	하는 일	산출
validate	스키마 · fixture 내부 경로 · 실제 줄 번호 확인, 모르는 필드 거부	파일 쓰지 않음
check	현재 인터프리터로 고정 unittest 명령만 30초 제한 실행	→ <code>check.json</code>
report	주장 · 체크 · 판정을 칸을 나눠 결합, 사례 해시가 바뀌면 거부	→ <code>report.md</code>
evaluate	real 사례만 집계, <code>unresolved</code> 는 정확도 분모에서 제외	→ 표준 출력 JSON

판정은 도구 밖에서

check 결과는 관찰일 뿐입니다. 주장의 참 · 거짓은 사람이 `verdicts.json`에 기록하고, 판정 전에는 `unresolved`로 둡니다.

신뢰 경계
JSON에 적힌 명령은 실행하지 않음
모델 API 호출 없음 · fixture 심볼릭 링크 거부
수정된 사례의 오래된 체크 재사용 거부
검토한 로컬 fixture만 실행

로컬 재현 예시 · `urllib3`

수정 전 `urllib3 assert_fingerprint()`에서 길이는 맞지만 16진수가 아닌 지문이 `SSLError` 대신 `binascii.Error`를 노출한 동작

공개 이슈 · github.com/urllib3/urllib3/issues/5211
수정 PR · github.com/urllib3/urllib3/pull/5212 · 다른 기여자가 병합

이 자료의 독립 발견 · 수정 성과 아님

주장	Claude finding · 실패 테스트를 본 상태에서 작성
체크	고정 unittest가 <code>binascii.Error</code> 로 실패 · 관찰일 뿐
판정	harness verdict <code>unresolved</code>

`sample_size 0` `precision null`

`ssl_.py` L107–138의 수정 전 함수를 분리한 로컬 fixture (MIT) · 로컬 대체 정의 사용, 전체 패키지 검증 아님

인계 파일의 항목마다 근거와 검토 상태가 함께 남는다

구현 · 브라우저 페이지 + 로컬 서버

in 원본 기록 넣기

끌어놓기·파일·붙여넣기·위치 선택 1-3개 · 합계 20,000자

01 초안: Claude CLI 또는 다른 AI

Claude CLI 직접 호출 · 또는 프롬프트 복사 → JSON 붙여넣기

02 스키마 · 인용문 정확 일치

필드·상태값·중복 ID · 일치 위치 표시

03 원본 옆 검토

편집해도 원래 AI 값 보존 · 모든 항목 '검토 필요'로 시작

out Markdown 내보내기

사용자가 work-handoff.md 다운로드

앱은 Claude CLI 버튼을 누를 때만 기록을 전송

· 앱 저장 없음

CSP connect-src 'self' → 로컬 /api/draft만

기록: Node 테스트 81개 통과 · 로컬 서버 경계(가짜 Claude CLI) 테스트 포함

내보낸 인계 파일 work-handoff.md 발췌

📄 원본 AI 값 ■ 기록 · 검토 후 값 ■ 검사 🟡 미확인

# Work Handoff	
■ 요약	Items: 5 (confirmed: 1, needs review: 4)
■ 검사 범위	Source quotations were checked for exact presence in the source records only; the app does not verify that claims are true.
🟡 사람 검토	Human review required: 4 item(s) are not confirmed and must be reviewed before relying on them.
### 3. item3 – needs_confirmation	
🟡 검토 상태	Review state: needs_review (human review required)
■ 최종 조치	Next action: QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정을 확정한다.
■ 편집 기록	Edited by reviewer: next_action
📄 원본 AI 값	Original AI draft · Next action: QA 승인 일정과 그에 따른 운영 배포 일정을 확정하기.
■ 인용 2	Source doc1 quote × 1 · Source doc2 quote × 1
### 1. item1 – completed	
■ 검토 결과	Review state: confirmed · Edited by reviewer: no · Source doc1 quote × 1

검토 상태

편집 이력

원문 인용

검토 상태

원문 그대로 발췌 · 원본 기록 2건 · 경고 3건 생략 · 5개 항목 중 2개 · 앱 내장 합성 예시로 실제 Claude 초안을 만든 뒤 내보낸 파일 · 검토자: AI 에이전트

Work Handoff: AI 초안을 원문 옆에서 검토하는 로컬 페이지

1 앱 · 기록 넣기 → 2 Claude CLI로 바로 초안 또는 다른 AI에서 프롬프트·JSON → 3 앱 · 인용 검사, 원본 옆 검토

기록 넣기

텍스트 파일을 여기에 끌어다 놓으세요

파일 고르기

원본 기록 위치 선택

직접 붙여넣기

예시로 체험하기

A 원본 기록 위치 선택: 고른 폴더 안의 후보만 · 읽기 전용

초안 경로

Claude CLI로 바로 초안 만들기

누를 때만 Claude CLI로 전송

다른 AI에서 초안 만들기

프롬프트 복사 → 원하는 AI → JSON 붙여넣기
· 앱은 다른 AI를 호출하지 않음

- 1 검토자가 수정
- 2 AI 초안 원래 값 보존
- 3 검토 필요 유지
- 4 원문 98번째 글자에서 정확히 일치

앱은 인용문이 원문에 글자 그대로 있는지만 확인합니다. 사실 여부와 기록 충돌은 검토하는 사람이 판단합니다. (앱 화면 문구 요약)

main 병합본 로컬 화면 · 앱 내장 합성 예시 기록 · 검토 화면은 저장된 실제 Claude 초안을 붙여넣어 재현(item3 다음 할 일 수정) · 사람 사용자 결과 아님

원본 옆 검토 · item3

종류

확인 필요 (needs_confirmation)

다음 할 일

QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정

내용

운영 서버 배포는 금요일 QA 승인 후로 계획되었으나, 팀 메모에서는 QA 승인이 다음 주 월요일로 미뤄졌다고 하여 배포 일정이 서로 다름.

수정됨 (next_action). AI 초안 원래 값 — 종류: 확인 필요 (needs_confirmation); 내용: 운영 서버 배포는 금요일 QA 승인 후로 계획되었으나, 팀 메모에서는 QA 승인이 다음 주 월요일로 미뤄졌다고 하여 배포 일정이 서로 다름.; 다음 할 일: QA 승인 일정과 그에 따른 운영 배포 일정을 확정하기.

검토 상태

☒ 검토 필요 ☐ 확인함

인용한 원문

doc1 — 예시: Claude 세션 – 결제 금액 버그 수정 (원문 98번째 글자에서 정확히 일치)
계획: 금요일 QA 승인 후 운영 서버에 배포.

합성 예시 기록 → 실제 Claude 초안 → AI 에이전트 검토

합성 원본 기록

앱 내장 예시 · 실제 업무 기록 아님

doc1 · 예시: Claude 세션 - 결제 금액 버그 수정

“...반올림 오류를 정수 단위(원) 계산으로 바꿔서 고쳤습니다. ... 계획: **금요일 QA 승인** 후 운영 서버에 배포. 막힘: ... OPS-118 ...”

doc2 · 예시: 팀 메모 - 배포 일정

“QA 승인은 **다음 주 월요일**로 미뤄졌습니다. 롤백 담당자는 아직 정해지지 않았습니다.”

실제 Claude 초안

로그인된 Claude CLI 응답 JSON 그대로

item1	completed	반올림 오류 수정
item2	completed	회귀 테스트 추가 · 로컬 42개 통과
item3	needs_confirmation	배포 일정이 두 기록에서 다름 (인용 2개)
item4	blocked	OPS-118 대기
item5	needs_confirmation	롤백 담당자 미정

경고 3건 · 날짜 불명 · 스테이징 검증 없음 · 커밋 정보 없음

■ 검증: 인용 6개 모두 원문과 정확 일치

검토 **AI 에이전트 · 사람 사용자 아님**

Codex 에이전트가 브라우저를 조작

item3 · next_action 수정

QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정을 확정한다.

상태 **needs_review** 유지

item1 **confirmed**

item2 · item4 · item5 **needs_review**

export · work-handoff.md

1 확인 4 검토 필요

사람 사용자의 검토 결과는 관찰·측정하지 않았습니다. 일정 충돌은 모델이 보고했고 앱은 자동 탐지하지 않습니다. 합성 사례 1건 시연 · 성능 지표 아님.

agent-workspace를 기준으로 분리 작업을 조율했다

직접 설계·제작 조율 SKILL.md는 역할과 수용 규칙을 정의하고, 실제 작업은 분리된 세션에서 진행

이번 작업에서 사용한 운영 흐름

01 기준

agent-workspace

규칙·결정 기록을 파일로 관리
tower preflight로 작업 대상 확인

실제 기록 · Work Handoff 제작 중 남은 리뷰 지적 1건

1 · 독립 리뷰어

재리뷰

지정 수정 8건 확인 뒤
Markdown 내보내기의 일부
줄바꿈 누락을 발견

02 분리 실행

Orca 작업 트리

작성자과 읽기 전용 리뷰어 분리
직접 만든 조율 스킬의 역할 규칙 적용

2 · 원 작성자

수정

줄바꿈 유형을 함께 처리
테스트 작성자가 단독 CR
회귀 사례를 추가

03 수용

조율 세션

리뷰 지적을 원 작성자에게 환류
검증 결과 확인 후 통합

3 · 같은 리뷰어

재검증

수정 범위를 다시 읽고
누락 해소 확인
결과 PASS

이후 조율자가 통합본을 수용 · 당시 기록: node --test 64/64, git diff --check

작성·리뷰·조율은 모두 에이전트 세션

사람 리뷰는 관찰하지 않았고, 조율 스킬은 앱에 자동 연결되지 않습니다.

다음 사람이 근거와 상태를 확인하며 이어받도록 설계

아직 측정하지 않음 주장하지 않음		실제 업무 효과 · 시간 절감 · 탐지 정확도 · 보안 효과 · 실제 사용자 도입 — 이 자료에 수치 없음
■ 관찰된 사실 한계 먼저		🟡 기대 효과 · 가설 측정 안 함
주 산출물 Work Handoff 로컬 웹 서비스 · 04-05, 07-09	실제 Claude 초안 1건 · 인용 6개 원문과 정확 일치 (합성 기록) 인계 파일 5항목 (확인 1 · 검토 필요 4) · 편집 전 AI 값 보존 검토는 AI 에이전트 · 사람 사용자 검토 미관찰 · 초안 경로 2개(다른 AI는 프롬프트/JSON 복사) · 앱 저장 없음 기록: Node 테스트 81/81	미확인 항목을 결론으로 넘기지 않고 근거와 함께 다시 확인
AI Evidence Review Python CLI · 06	판정 unresolved · sample_size 0 · precision null 공개 이슈 #5211 수정 전 동작을 로컬 fixture로 재현 · 수정 PR #5212는 다른 기여자가 병합	판정 전 AI 주장을 결론으로 쓰지 않음
에이전트 작업 조율 스킴 직접 제작 SKILL.md · 10	재리뷰가 찾은 CR 줄바꿈 누락 → 원 작성자 수정 → 같은 리뷰어 재검증 PASS 작성·리뷰·조율 모두 에이전트 세션 기록: 통합본 테스트 64/64	작성·리뷰·통합 책임과 수정 이력을 추적

세 사례는 같은 원칙의 독립 구현이며 런타임으로 자동 연결되지 않습니다.