


AI 결과를 검증 가능한 인계로

AI 에이전트의 결과를 사람과 다음 에이전트가 근거와 함께
이어받도록, 검증 가능한 인계 도구를 설계하고 구현합니다.

AI 제안 · 근거 확인 · 검토 · 수용을 연결하는 하네스



개념도 · AI 초안의 각 내용이 결정적 검사와 검토를 거쳐, 상태와 함께 인계 파일에 남는다
Work Handoff · AI Evidence Review · 에이전트 작업 조율 스킬은 런타임으로 연결되지 않은 독립 구현

01 Work Handoff 대표 05-10

로컬 웹 서비스 · 인용 검사와 검증 가능한 Markdown 인계

02 AI Evidence Review ¹²

Python CLI · 주장 · 체크 · 판정 분리

03 에이전트 작업 조율 스킬 ¹⁴

직접 설계·제작한 SKILL.md · 작성 · 리뷰 · 수용 게이트

이진웅 | 3년차 AI 엔지니어

LangGraph·vLLM·FastAPI 기반 온프레미스 RAG 솔루션 설계·구축

이번 포트폴리오: AI 에이전트 결과를 근거·검토 상태와 함께 인계하는 도구

이 포트폴리오의 세 사례

사례	형태	장	저장소
01 Work Handoff 대표	로컬 웹 서비스 · 인용 검사와 검증 가능한 Markdown 인계	05-10	github.com/dtype2100/work-handoff
02 AI Evidence Review	Python CLI · 주장 · 체크 · 판정 분리	12	github.com/dtype2100/ai-evidence-review
03 에이전트 작업 조율 스킴	직접 설계·제작한 SKILL.md · 작성 · 리뷰 · 수용 게이트	14	github.com/dtype2100/orca-orchestrate-engineering

결론만 넘겨받으면 근거를 다시 확인하기 어렵다

AI 결론만 전달되면 검토자와 다음 담당자는 원문 · 실행 증거 · 판정 상태를 다시 확인하기 어렵습니다.

① 작업 인계 요약 → Work Handoff

세션 A · 화 “Migration finished on Tuesday ...”

세션 B · 수 “Migration still running as of Wednesday ...”

합성 예시 기록 발췌 · examples/conflict

빠진 것 두 기록의 상태가 서로 어긋난다는 점, 각 문장이 어느 원문에서 왔는지

후속 판단 위험 요약이 한쪽만 옮기면 “완료”로 넘어가 다음 담당자가 확인되지 않은 상태 위에서 작업

② AI 코드 리뷰 결론 → AI Evidence Review

AI 리뷰 결론 한 문단

원인 추정

“테스트로 확인했다”는 말

수정 · 병합 권고

구조 도식 · 특정 문장을 옮긴 것이 아님

빠진 것 어떤 테스트를 어떻게 실행했는지, 그 결과가 주장을 입증하는지 누가 판단했는지

후속 판단 위험 실행했다는 말만 믿고 원인 추정을 사실로 삼아 수정 · 병합을 결정

Work Handoff

원문·인용·검토 상태를
함께 넘기는 로컬 서비스

독립 구현 사례



Work Handoff: 초안 경로는 둘, 인용 검사와 검토는 같다

— 파일 · 원본 기록 [🔍] 앱 밖 · 검사 전까지 미신뢰 [🔍] 로컬 검사 · 검토 (브라우저 안)

2 AI 초안 만들기 · 한 개의 실행 버튼

Claude CLI 로그인된 로컬 CLI로 자동 실행 · 버튼을 누를 때 기록 전송
GPT·Gemini·Codex·기타 프롬프트 복사 → AI 대화창 → JSON 붙여넣기
두 방식 모두 앱에서 같은 스키마·인용 검사와 원문 옆 검토를 거칩니다.

① 원본 기록

파일 끌어놓기·선택·붙여넣기·원본 기록
위치 선택 1-3개
합계 20,000자 이하
위치 선택: 사용자가 고른 폴더 안의 후보만 읽기 전용 ·
앱은 거기에 쓰지 않음

Work Handoff · 브라우저 페이지 + 로컬 Python 서버

- | | | |
|---|-----------|-----------------------|
| 4 | 스키마 검사 | 필드 · 상태값 · 중복 ID · 길이 |
| 5 | 인용문 정확 일치 | 지정한 원문에 그대로 있는지 |
| 6 | 원본 옆 검토 | 편집 · 확인 / 검토 필요 지정 |

경계 · Claude CLI 선택 후 실행할 때만 기록 전송
다른 AI 선택 시 앱은 전송하지 않음 · 사용자가 직접 복사
앱은 인용만 검사 · 진위와 충돌은 검토자가 판단

⑦ Markdown 인계

work-handoff.md
사용자가 다운로드
원본 AI 값 · 최종 값 · 인용 · 검토
상태 · 경고
미확인 항목에 “사람 검토 필요”
표시

⑧ 다음 에이전트

인계 파일과 원문을 다시 읽고
이어서 작업
설계상 흐름 · 사용 효과 미측정

인계 파일이 다음 세션의 파일 문맥이 됨 · 사람이 옮기거나 저장소에 둬, 자동 동기화 없음 → 06

같은 원칙의 독립 구현

AI Evidence Review 별도 Python CLI · 코드 리뷰 주장과 고정 테스트 결과를 나눠 기록 (12)
에이전트 작업 조율 스킬 직접 설계·제작한 SKILL.md, Work Handoff 제작에 쓴 작업 운영 방식 (14) · 둘 다 이 흐름과 런타임으로 연결되지 않음

기억 공유는 파일로: 남긴 파일을 다음 작업에서 다시 열 수 있다

사람

파일을 저장소에
두거나 파일 위치를
다음 작업 지시에 적음

남긴다

규칙 · 계약 .md

AGENTS.md
docs/run-
contract.md

역할 · 소유 경로 · 검사 · 수용
기준을 적은 파일

결정 위키 .md

llm-wiki/wiki/
index.md

결정마다 출처 라벨

사용자 결정 저장소 확인

관찰 미결

인계 파일 .md

work-handoff.md

항목별 원문 인용 · 검토 상태 ·
다음 조치

다시 열 수 있음

다음
에이전트

다음 작업 지시에서 인계
파일을 다시 열도록
지정할 수 있음

한계

자동 동기화 없음

앱에 저장하지 않음

실제 사용 · 효과는 관찰하지 않음

인계 파일의 항목마다 근거와 검토 상태가 함께 남는다

구현 · 브라우저 페이지 + 로컬 서버

in 원본 기록 넣기

끌어놓기·파일·붙여넣기·위치 선택 1-3개 · 합계 20,000자

01 선택한 AI로 초안

Claude CLI 자동 · GPT/Gemini 등 직접 같은 JSON 검증으로 이동

02 스키마 · 인용문 정확 일치

필드·상태값·중복 ID · 일치 위치 표시

03 원본 옆 검토

편집해도 원래 AI 값 보존 · 모든 항목 '검토 필요'로 시작

out Markdown 내보내기

사용자가 work-handoff.md 다운로드

Claude CLI 선택 후 실행할 때만 기록 전송

다른 AI는 앱 전송 없음 · 앱 저장 없음

CSP connect-src 'self' → 로컬 /api/draft만

기록: Node 테스트 81개 통과 · 로컬 서버 경계(가짜 Claude CLI) 테스트 포함

내보낸 인계 파일 work-handoff.md 발췌

📄 원본 AI 값 ■ 기록 · 검토 후 값 ■ 검사 🟡 미확인

# Work Handoff	
■ 요약	Items: 5 (confirmed: 1, needs review: 4)
■ 검사 범위	Source quotations were checked for exact presence in the source records only; the app does not verify that claims are true.
🟡 사람 검토	Human review required: 4 item(s) are not confirmed and must be reviewed before relying on them.
### 3. item3 – needs_confirmation	
🟡 검토 상태	Review state: needs_review (human review required)
■ 최종 조치	Next action: QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정을 확정한다.
■ 편집 기록	Edited by reviewer: next_action
📄 원본 AI 값	Original AI draft · Next action: QA 승인 일정과 그에 따른 운영 배포 일정을 확정하기.
■ 인용 2	Source doc1 quote × 1 · Source doc2 quote × 1
### 1. item1 – completed	
■ 검토 결과	Review state: confirmed · Edited by reviewer: no · Source doc1 quote × 1

검토 상태

편집 이력

원문 인용

검토 상태

원문 그대로 발췌 · 원본 기록 2건 · 경고 3건 생략 · 5개 항목 중 2개 · 앱 내장 합성 예시로 실제 Claude 초안을 만든 뒤 내보낸 파일 · 검토자: AI 에이전트

한 번 선택하고 초안을 만든다

자동 실행은 Claude CLI, ChatGPT·Gemini·Codex·기타 AI는 프롬프트와 JSON을 직접 전달

2. AI 초안 만들기

사용할 AI를 고르세요. 어느 경로든 같은 인용 검사·검토·내보내기를 거칩니다. 인용문이 원문에 있어도 내용이 사실이라는 뜻은 아닙니다.

사용할 AI와 초안 방식

☒ ChatGPT / GPT · 직접

☐ Claude CLI · 자동

☐ Gemini · 직접

☐ Codex · 직접

☐ 다른 AI · 직접

프롬프트 준비하기

앱은 ChatGPT / GPT에 연결되지 않습니다. 버튼을 누르면 프롬프트를 만들고, 직접 복사해 이미 쓰는 대화창에 붙여넣습니다. 받은 JSON도 직접 가져옵니다. 이 단계에서 앱은 기록을 보내지 않습니다.

Claude CLI만 자동 실행합니다. 실행 버튼을 누르기 전에는 기록을 보내지 않습니다. 앱에 API 키·새 구독·결제 설정은 없습니다.

- ▶ 직접 붙여넣기: 프롬프트를 복사해 AI 대화창에 넣고 JSON 답변 받기
- ▶ 자세한 사용 안내

Claude CLI · 자동

기존 로그인으로 실행 · 버튼을 눌러야 기록 전송

실제 브라우저 캡처 · GPT 선택 상태 · 기록을 보내기 전 화면

다른 AI · 직접

앱은 연결하지 않음 · 프롬프트 복사와 JSON 붙여넣기

원문 옆에서 초안을 고치고 검토 상태를 남긴다

저장된 실제 Claude 초안을 불러와 item3의 다음 할 일을 수정한 화면

기록을 넣고

텍스트 파일을 여기에 끌어다 놓으세요

파일 고르기

원본 기록 위치 선택

직접 붙여넣기

예시로 체험하기

원문 옆에서 확인

- 01 수정한 값과 원래 AI 값 보존
- 02 검토 필요 상태 유지
- 03 인용 위치를 원문에서 확인

검토자는 AI 에이전트였습니다.
사람 사용자 검토 결과는 관찰하지 않았습니다.

종류

다음 할 일

확인 필요 (needs_confirmation) ▾

QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정

내용

운영 서버 배포는 금요일 QA 승인 후로 계획되었으나, 팀 메모에서는 QA 승인이 다음 주 월요일로 미뤄졌다고 하여 배포 일정이 서로 다름.

수정됨 (next_action). AI 초안 원래 값 — 종류: 확인 필요 (needs_confirmation); 내용: 운영 서버 배포는 금요일 QA 승인 후로 계획되었으나, 팀 메모에서는 QA 승인이 다음 주 월요일로 미뤄졌다고 하여 배포 일정이 서로 다름.; 다음 할 일: QA 승인 일정과 그에 따른 운영 배포 일정을 확정하기.

검토 상태

☒ 검토 필요

☐ 확인함

인용한 원문

doc1 — 예시: Claude 세션 – 결제 금액 버그 수정 (원문 98번째 글자에서 정확히 일치)

계획: 금요일 QA 승인 후 운영 서버에 배포.

합성 예시 기록 → 실제 Claude 초안 → AI 에이전트 검토

합성 원본 기록

앱 내장 예시 · 실제 업무 기록 아님

doc1 · 예시: Claude 세션 - 결제 금액 버그 수정

“...반올림 오류를 정수 단위(원) 계산으로 바꿔서
고쳤습니다. ... 계획: **금요일 QA 승인** 후 운영 서버에
배포. 막힘: ... OPS-118 ...”

doc2 · 예시: 팀 메모 - 배포 일정

“QA 승인은 **다음 주 월요일**로 미뤄졌습니다. 롤백
담당자는 아직 정해지지 않았습니다.”

실제 Claude 초안

로그인된 Claude CLI 응답 JSON 그대로

item1	completed 반올림 오류 수정
item2	completed 회귀 테스트 추가 · 로컬 42개 통과
item3	needs_confirmation 배포 일정이 두 기록에서 다름 (인용 2개)
item4	blocked OPS-118 대기
item5	needs_confirmation 롤백 담당자 미정

경고 3건 · 날짜 불명 · 스테이징 검증 없음 · 커밋 정보 없음

■ 검증: 인용 6개 모두 원문과 정확 일치

검토 AI 에이전트 · 사람 사용자 아님

Codex 에이전트가 브라우저를 조작

item3 · next_action 수정

QA 승인 날짜를 팀에 다시 확인하고 운영 배포 일정을
확정한다.

상태 **needs_review** 유지

item1 **confirmed**

item2 · item4 · item5 **needs_review**

export · work-handoff.md

1 확인 4 검토 필요

사람 사용자의 검토 결과는 관찰·측정하지 않았습니다. 일정 충돌은 모델이 보고했고 앱은 자동 탐지하지 않습니다. 합성 사례 1건 시연 · 성능 지표 아님.

AI Evidence Review

주장·체크·판정을 분리해
검증 범위를 드러낸다

독립 구현 사례



AI Evidence Review: 주장 · 체크 · 판정을 파일로 분리

명령	하는 일	산출
validate	스키마 · fixture 내부 경로 · 실제 줄 번호 확인, 모르는 필드 거부	파일 쓰지 않음
check	현재 인터프리터로 고정 unittest 명령만 30초 제한 실행	→ <code>check.json</code>
report	주장 · 체크 · 판정을 칸을 나눠 결합, 사례 해시가 바뀌면 거부	→ <code>report.md</code>
evaluate	real 사례만 집계, <code>unresolved</code> 는 정확도 분모에서 제외	→ 표준 출력 JSON

판정은 도구 밖에서

check 결과는 관찰일 뿐입니다. 주장의 참 · 거짓은 사람이 `verdicts.json`에 기록하고, 판정 전에는 `unresolved`로 둡니다.

신뢰 경계
JSON에 적힌 명령은 실행하지 않음
모델 API 호출 없음 · fixture 심볼릭 링크 거부
수정된 사례의 오래된 체크 재사용 거부
검토한 로컬 fixture만 실행

로컬 재현 예시 · `urllib3`

수정 전 `urllib3 assert_fingerprint()`에서 길이는 맞지만 16진수가 아닌 지문이 `SSLError` 대신 `binascii.Error`를 노출한 동작

공개 이슈 · github.com/urllib3/urllib3/issues/5211
수정 PR · github.com/urllib3/urllib3/pull/5212 · 다른 기여자가 병합

이 자료의 독립 발견 · 수정 성과 아님

주장	Claude finding · 실패 테스트를 본 상태에서 작성
체크	고정 unittest가 <code>binascii.Error</code> 로 실패 · 관찰일 뿐
판정	harness verdict <code>unresolved</code>


`sample_size 0` `precision null`

`ssl_.py` L107–138의 수정 전 함수를 분리한 로컬 fixture (MIT) · 로컬 대체 정의 사용, 전체 패키지 검증 아님

에이전트 작업 조율 스킴

작성·리뷰·수정·재검증을
분리해 운영한 사례

직접 설계·제작한 SKILL.md



agent-workspace를 기준으로 분리 작업을 조율했다

직접 설계·제작 조율 SKILL.md는 역할과 수용 규칙을 정의하고, 실제 작업은 분리된 세션에서 진행

이번 작업에서 사용한 운영 흐름

01 기준

agent-workspace

규칙·결정 기록을 파일로 관리
tower preflight로 작업 대상 확인

실제 기록 · Work Handoff 제작 중 남은 리뷰 지적 1건

1 · 독립 리뷰어

재리뷰

지정 수정 8건 확인 뒤
Markdown 내보내기의 일부
줄바꿈 누락을 발견

02 분리 실행

Orca 작업 트리

작성자과 읽기 전용 리뷰어 분리
직접 만든 조율 스킬의 역할 규칙 적용

2 · 원 작성자

수정

줄바꿈 유형을 함께 처리
테스트 작성자가 단독 CR
회귀 사례를 추가

03 수용

조율 세션

리뷰 지적을 원 작성자에게 환류
검증 결과 확인 후 통합

3 · 같은 리뷰어

재검증

수정 범위를 다시 읽고
누락 해소 확인
결과 PASS

이후 조율자가 통합본을 수용 · 당시 기록: node --test 64/64, git diff --check

작성·리뷰·조율은 모두 에이전트 세션

사람 리뷰는 관찰하지 않았고, 조율 스킬은 앱에 자동 연결되지 않습니다.

AI Harness · 14 / 16

다음 사람이 근거와 상태를 확인하며 이어받도록 설계

아직 측정하지 않음 주장하지 않음		실제 업무 효과 · 시간 절감 · 탐지 정확도 · 보안 효과 · 실제 사용자 도입 — 이 자료에 수치 없음
■ 관찰된 사실 한계 먼저		🟡 기대 효과 · 가설 측정 안 함
주 산출물 Work Handoff 로컬 웹 서비스 · 05-10	실제 Claude 초안 1건 · 인용 6개 원문과 정확 일치 (합성 기록) 인계 파일 5항목 (확인 1 · 검토 필요 4) · 편집 전 AI 값 보존 검토는 AI 에이전트 · 사람 사용자 검토 미관찰 · 초안 경로 2개(다른 AI는 프롬프트/JSON 복사) · 앱 저장 없음 기록: Node 테스트 81/81	미확인 항목을 결론으로 넘기지 않고 근거와 함께 다시 확인
AI Evidence Review Python CLI · 12	판정 unresolved · sample_size 0 · precision null 공개 이슈 #5211 수정 전 동작을 로컬 fixture로 재현 · 수정 PR #5212는 다른 기여자가 병합	판정 전 AI 주장을 결론으로 쓰지 않음
에이전트 작업 조율 스킴 직접 제작 SKILL.md · 14	재리뷰가 찾은 CR 줄바꿈 누락 → 원 작성자 수정 → 같은 리뷰어 재검증 PASS 작성·리뷰·조율 모두 에이전트 세션 기록: 통합본 테스트 64/64	작성·리뷰·통합 책임과 수정 이력을 추적

세 사례는 같은 원칙의 독립 구현이며 런타임으로 자동 연결되지 않습니다.



감사합니다.

AI 결과를 근거와 검토 상태로 이어받도록 설계했습니다.

이진웅 · AI Engineer

github.com/dtype2100